

Universidad Nacional
de Educación a Distancia

Facultad de Ciencias Económicas y Empresariales

Departamento de Economía Aplicada y Estadística

Redes neuronales artificales para la Predicción de Precios de Acciones en la Bolsa de Valores

Paloma Guiral Ortuño

Director: Alberto Muñoz Cabanes

Trabajo de Fin de Máster

Máster
en Machine Learning

Septiembre 2024

Resumen

La predicción de precios de acciones es esencial para los inversores debido a la volatilidad del mercado bursátil. Con el avance en técnicas de aprendizaje automático, particularmente en redes neuronales, se ha mejorado la capacidad de modelar y prever estas fluctuaciones. Este Trabajo de Fin de Máster explora la aplicación de diferentes arquitecturas de redes neuronales artificiales para la predicción de precios de acciones en la Bolsa de Valores, centrando el análisis en cuatro modelos: Redes Neuronales Recurrentes (RNN), Long Short-Term Memory (LSTM), LSTM con capa convolucional 1D (Conv1D-LSTM), y Gated Recurrent Unit (GRU).

Se emplearon datos históricos de precios de la acción de Inditex, junto con varios indicadores técnicos como SMA, MACD, RSI, EMA, CCI, VWAP y Williams %R. Los modelos fueron entrenados y evaluados usando métricas estándar, incluyendo el error cuadrático medio (RMSE). Los resultados indicaron que el modelo GRU con las variables 'Open', 'High', 'Low', 'Volume', 'Adj Close' mostró el menor RMSE, destacándose como el más preciso para la predicción del precio de cierre ajustado.

El estudio sugiere que futuras investigaciones podrían beneficiarse de la optimización de hiperparámetros y la incorporación de análisis de sentimiento basado en noticias financieras para mejorar aún más la precisión de las predicciones.

Palabras clave: Predicción de precios de acciones, redes neuronales artificiales, RNN, LSTM, GRU, aprendizaje profundo, Bolsa de Valores, indicadores técnicos

Abstract

Predicting stock prices is crucial for investors due to market volatility. With advancements in machine learning techniques, particularly in neural networks, the ability to model and forecast these fluctuations has improved. This Master's Thesis explores the application of various artificial neural network architectures for stock price prediction on the Stock Exchange, focusing on four models: Recurrent Neural Networks (RNN), Long Short-Term Memory (LSTM), LSTM with 1D Convolutional Layer (Conv1D-LSTM), and Gated Recurrent Unit (GRU).

Data used include historical stock prices of Inditex, along with several technical indicators such as SMA, MACD, RSI, EMA, CCI, VWAP, and Williams %R. The models were trained and evaluated using standard metrics, including Mean Squared Error (MSE). Results showed that the GRU model with variables 'Open', 'High', 'Low', 'Volume', 'Adj Close' achieved the lowest RMSE, emerging as the most accurate for predicting the adjusted closing price.

The study suggests that future research could benefit from hyperparameter optimization and the integration of sentiment analysis based on financial news to further enhance prediction accuracy.

Keywords: Stock price prediction, artificial neural networks, RNN, LSTM, GRU, deep learning, Stock Exchange, technical indicators

Índice general

1. Introducción **1**
1.1. Motivación 2
1.2. Propuesta y objetivos 3
1.3. Estructura del documento 4

2. Materiales y métodos **5**
2.1. Lenguaje de programación 5
2.2. Librerías 5

3. La bolsa de valores **7**
3.1. ¿Qué es la Bolsa de Valores? 7
3.1.1. Acciones 7
3.2. Predicción en Bolsa 8
3.2.1. Análisis Fundamental 8
3.2.2. Análisis Técnico 8
3.3. Predicción con Machine Learning 9
3.4. Conclusión 10

4. Datos utilizados en los modelos de predicción **11**
4.1. Acción seleccionada 11
4.2. Datos 11
4.2.1. Datos financieros históricos 11
4.2.2. Indicadores técnicos 12
4.3. Variables utilizadas 12
4.3.1. Variable dependiente 12
4.3.2. Variables independientes 12

5. Arquitecturas de redes neuronales **15**
5.1. Redes Neuronales Recurrentes (RNN) 15
5.1.1. Ventajas de las RNN para la predicción de precios 15
5.1.2. Estructura 15

5.2. Long Short-Term Memory (LSTM) 16
5.2.1. Ventajas de las LSTM para la predicción de precios 16
5.2.2. Estructura 16
5.3. LSTM con Capa Convolucional 1D 16
5.3.1. Ventajas de las LSTM con Capa Convolucional 1D para la predicción de precios 17
5.3.2. Estructura 17
5.4. Gated Recurrent Unit (GRU) 17
5.4.1. Ventajas de las GRU para la predicción de precios 18
5.4.2. Estructura 18

6. Resultados **19**

7. Conclusiones y trabajos futuros **23**
7.1. Trabajos futuros 24

Bibliografía y referencias **25**

Índice de figuras

7.1. gráfica GRU1 24

Índice de tablas

6.1. RNN simple - Modelos y métricas 20
6.2. LSTM - Modelos y métricas 20
6.3. CNN LSTM - Modelos y métricas 20
6.4. GRU - Modelos y métricas 21

7.1. Modelos con los 7 valores más bajos de RMSE 23

Capítulo 1

Introducción

En el mundo financiero, la predicción de los precios de las acciones ha sido durante décadas un desafío constante que atrae tanto a inversores como a investigadores. La capacidad de anticipar movimientos futuros del mercado no solo ofrece el potencial de maximizar ganancias, sino que también permite mitigar riesgos significativos. Sin embargo, debido a la naturaleza volátil y del mercado de valores, prever con precisión los precios de las acciones sigue siendo una tarea extremadamente compleja.

Históricamente, los modelos financieros tradicionales han intentado explicar las fluctuaciones del mercado mediante análisis fundamentales y técnicos, pero con un éxito limitado. Una de las teorías más influyentes en la economía financiera es la Hipótesis del Paseo Aleatorio (Random Walk Hypothesis) Rankia (2023), que sugiere que los precios de los activos financieros siguen un camino impredecible y, por tanto, no pueden ser anticipados de manera consistente. Según esta hipótesis, los movimientos de los precios son aleatorios y cualquier intento de predecir el mercado sería infructuoso. No obstante, en la última década, la aparición de nuevas técnicas basadas en inteligencia artificial ha desafiado este concepto.

El desarrollo de modelos de Machine Learning (ML) y, en particular, de redes neuronales artificiales Amazon Web Services (2024), ha abierto nuevas oportunidades para el análisis y predicción de datos financieros. Estos modelos, que son capaces de aprender patrones no lineales complejos a partir de grandes volúmenes de datos históricos, ofrecen la posibilidad de generar predicciones más precisas en comparación con los métodos tradicionales. A medida que los mercados generan una gran cantidad de datos cada segundo, como los precios de las acciones, los volúmenes de negociación y una serie de indicadores técnicos, las redes neuronales pueden aprovechar estas características para detectar patrones ocultos y realizar proyecciones más fundamentadas.

En este trabajo, nos centraremos en explorar la capacidad de diferentes arquitecturas de redes neuronales para predecir los precios de las acciones. En concreto, se implementarán y evaluarán cuatro modelos distintos de redes neuronales:

1. Red Neuronal Recurrente (RNN): Este tipo de red es ideal para secuencias de datos,

como las series temporales, debido a su capacidad para mantener información a lo largo del tiempo, capturando así dependencias temporales en los datos históricos de precios.

2. LSTM (Long Short-Term Memory): Una variante de las redes neuronales recurrentes que resuelve problemas relacionados con la memoria a largo plazo. Las LSTM están diseñadas para superar el problema del desvanecimiento del gradiente **?** y son especialmente útiles cuando las secuencias de datos tienen dependencias a largo plazo.

3. LSTM con una capa convolucional de 1 dimensión (Conv1D-LSTM): Este modelo combina las ventajas de las redes convolucionales (CNN), que son excelentes para extraer características de series temporales, con las capacidades de memoria de las LSTM. La CNN extrae patrones locales de los datos de series temporales, mientras que la LSTM se encarga de las dependencias temporales más largas.

4. Gated Recurrent Unit (GRU): Es un tipo de arquitectura de red neuronal recurrente similar a la LSTM. Al igual que la LSTM, la GRU está diseñada para modelar datos secuenciales permitiendo que la información se recuerde u olvide selectivamente a lo largo del tiempo. Sin embargo, GRU tiene una arquitectura más simple que LSTM, con menos parámetros, lo que puede hacer que sea más fácil de entrenar y más eficiente computacionalmente Anishnama (2023).

Para entrenar y evaluar estos modelos, se emplearán diferentes conjuntos de datos, que incluirán tanto los precios históricos de las acciones como una variedad de indicadores técnicos Central Charts (2024). Se realizarán combinaciones de diferentes bases de datos con los tres tipos de modelos mencionados. Posteriormente, se utilizarán métricas de evaluación estándar Sitio Big Data (2018), como el error cuadrático medio (MSE) para seleccionar el modelo más preciso y robusto.

El principal objetivo de este trabajo es determinar qué modelo de red neuronal artificial proporciona las predicciones más precisas en función de las combinaciones de datos empleadas. A través de este análisis, se espera clarificar el potencial de las técnicas de Machine Learning para mejorar las estrategias de inversión en los mercados financieros y, a su vez, contribuir al desarrollo de modelos más precisos para la predicción de precios en la bolsa de valores.

1.1. Motivación

La motivación detrás de este proyecto radica en la necesidad de desarrollar herramientas más precisas y eficientes para predecir los precios de las acciones. Las estrategias tradicionales, como el análisis técnico y fundamental, aunque fundamentales, a menudo no logran capturar la complejidad de los mercados modernos.

El empleo de algoritmos de Machine Learning y Deep Learning ofrece una alternativa prometedora, ya que permite explorar patrones complejos y relaciones no evidentes en grandes volúmenes de datos históricos y actuales. Esto no solo mejora la capacidad predictiva frente a los métodos convencionales, sino que también permite desarrollar modelos que se adaptan mejor a las condiciones cambiantes del mercado. Además, los avances recientes, como la disponibilidad de mayores capacidades de cómputo (a través de GPUs y cloud computing) y el acceso a grandes conjuntos de datos financieros, han hecho que la implementación de estas técnicas sea más viable.

Este proyecto busca, por lo tanto, contribuir al desarrollo de soluciones tecnológicas que respondan a las necesidades del mercado financiero moderno, donde las herramientas tradicionales ya no son suficientes para abordar los la complejidad de las dinámicas de precios.

1.2. Propuesta y objetivos

Los objetivos de este trabajo son los siguientes:

1. Exploración de Datos y Preprocesamiento: Recopilar datos históricos precisos y relevantes de fuentes financieras para su análisis y de indicadores técnicos.

2. Selección y Evaluación de Modelos: Comparar varias arquitecturas de redes neuronales, para determinar un modelo que ofrezca la mejor precisión en la predicción de precios de acciones.

3. Análisis del Sentimiento en Noticias Financieras: Investigar y evaluar el impacto del análisis del sentimiento de noticias financieras en la predicción de los precios de las acciones, incorporando técnicas de procesamiento de lenguaje natural (NLP) para determinar si el sentimiento positivo o negativo en las noticias puede mejorar la precisión de los modelos predictivos.

4. Incorporación de Variables y Modelos: Experimentar con diferentes conjuntos de características, que incluyen datos de precios históricos, así como indicadores técnicos y análisis de noticias financieras, para optimizar el rendimiento predictivo.

5. Análisis Comparativo: Evaluar el rendimiento de los modelos mediante métricas estándar como el Error Absoluto Medio (MAE), Error Medio Cuadrado (MSE) y el Error Cuadrático Medio (RMSE), para determinar cuál modelo y conjunto de características proporcionan las predicciones más precisas y estables.

1.3. Estructura del documento

El documento comienza con una introducción en la que se exploran la motivación detrás del estudio, así como la propuesta y los objetivos del trabajo.

Seguidamente, se describen los materiales y métodos utilizados, incluyendo el lenguaje de programación y las librerías empleadas. Luego, se presenta un análisis detallado de la Bolsa de Valores, abordando conceptos clave y métodos de predicción en el contexto del mercado financiero.

En la sección dedicada a los datos utilizados, se detalla la selección de la acción estudiada, los datos financieros históricos y los indicadores técnicos que se han integrado en los modelos de predicción. Posteriormente, se discuten las diferentes arquitecturas de redes neuronales aplicadas en el estudio, destacando sus ventajas y estructuras específicas.

Finalmente, el documento presenta los resultados obtenidos a partir de los modelos evaluados y concluye con un análisis de los hallazgos, además de proponer posibles direcciones para investigaciones futuras.

Capítulo 2

Materiales y métodos

2.1. Lenguaje de programación

El lenguaje de programación Python Python Software Foundation (2024) ha sido seleccionado para el desarrollo del presente trabajo debido a sus capacidades técnicas avanzadas, su amplio uso en el ámbito de la ciencia de datos y su aplicabilidad en el análisis financiero.

Python dispone de una amplia gama de bibliotecas y frameworks que facilitan la implementación de algoritmos de machine learning, como 'scikit-learn', 'TensorFlow', 'Keras', y 'PyTorch', entre otros. Estas herramientas permiten realizar tareas complejas de modelado y análisis con gran flexibilidad. Además, Python destaca por sus capacidades para la visualización de datos a través de bibliotecas como 'Matplotlib', 'Seaborn', y 'Plotly', que permiten crear gráficos y visualizaciones interactivas y detalladas.

Además, otro factor crucial es la capacidades de R para la visualización de datos, creación de gráficos y visualizaciones interactivas y detalladas.

2.2. Librerías

Para el desarrollo del presente trabajo se han utilizado diversas librerías que son fundamentales para la manipulación de datos, el modelado y la visualización. A continuación, se destacan las principales:

- 'pandas' y 'numpy' han sido empleadas para la manipulación y análisis de datos.
- 'yfinance' ha facilitado la obtención de datos financieros históricos.
- 'sklearn' ofrece herramientas para el preprocesamiento de datos y la evaluación de modelos, incluyendo 'MinMaxScaler' para la normalización y métricas como 'mean_absolute_error' y 'mean_squared_error'.

- 'tensorflow' y 'tensorflow.keras' han sido utilizadas para la construcción y entrenamiento de modelos de redes neuronales, incluyendo las capas 'LSTM', 'GRU', 'SimpleRNN', 'Dense', 'Dropout', 'Conv1D' y 'MaxPooling1D', así como el 'EarlyStopping' para el control del entrenamiento.
- 'matplotlib' ha sido utilizada para la creación de gráficos y visualizaciones.
- 'math' se ha utilizado para funciones matemáticas adicionales, como la raíz cuadrada.

Estas librerías proporcionan un conjunto completo de herramientas para el análisis y modelado de datos, esenciales para la predicción de precios de acciones.

Capítulo 3

La bolsa de valores

La bolsa de valores es un mercado en el que se intercambian acciones de compañías públicas y otros instrumentos financieros. Representa un componente clave del sistema financiero global, ya que facilita el acceso a capital para las empresas y ofrece oportunidades de inversión para los individuos e instituciones. En esta sección, se describen los elementos principales de la bolsa de valores y cómo se utilizan las acciones como medio de inversión y especulación.

3.1. ¿Qué es la Bolsa de Valores?

Una bolsa de valores es un mercado público donde se pueden comprar y vender acciones de compañías que cotizan en ella y Mercados (2024). Estas acciones, también conocidas como *equities*, representan una parte proporcional de la propiedad en una empresa. Las bolsas de valores, como la Bolsa de Madrid, actúan como intermediarias que permiten el intercambio eficiente de estos activos entre inversores.

El precio de las acciones en la bolsa está determinado por la oferta y la demanda. Los inversores compran acciones con la expectativa de que su valor aumente, mientras que los vendedores lo hacen con la idea de obtener beneficios o reducir pérdidas. Cada transacción en la bolsa de valores refleja la percepción de los participantes sobre el valor futuro de las acciones, basada en factores como el rendimiento de la empresa, la economía global y eventos políticos CNMV (2024).

3.1.1. Acciones

Una acción es una prueba de propiedad en una corporación. Al poseer acciones, el inversor tiene derecho a una parte proporcional de los activos y las ganancias de la compañía. Las acciones pueden generar rendimientos a través del aumento de su valor de mercado (ganancia de capital) y el pago de dividendos XTB (2024).

En el contexto de la bolsa de valores, los precios de las acciones fluctúan constantemente según las condiciones del mercado, que están influenciadas por una variedad de factores internos (resultados financieros de la empresa) y externos (eventos económicos, políticos, etc.).

3.2. Predicción en Bolsa

Predecir los movimientos futuros de los precios de las acciones es uno de los mayores desafíos en el mundo financiero. Dado que el mercado de valores es notoriamente volátil y está influenciado por una gran cantidad de factores, la predicción de precios es una tarea compleja. A lo largo de los años, los analistas han desarrollado dos enfoques principales para intentar predecir los precios: el análisis fundamental y el análisis técnico Castell (2020).

3.2.1. Análisis Fundamental

El análisis fundamental se basa en el estudio detallado de los datos financieros de la empresa y las condiciones económicas generales para evaluar el valor intrínseco de una acción Degiro (2024). Los analistas fundamentales examinan factores como los ingresos, ganancias, dividendos y perspectivas de crecimiento, así como el entorno económico general y las condiciones del sector en el que opera la empresa. Este enfoque busca determinar si una acción está subvalorada o sobrevalorada en función de su valor real.

3.2.2. Análisis Técnico

El análisis técnico, por otro lado, se centra en los patrones de los precios históricos y el volumen de transacciones para predecir los futuros movimientos del precio de una acción. Este enfoque asume que toda la información relevante ya está reflejada en el precio de la acción y que los movimientos de precios tienden a seguir tendencias que se pueden identificar a través de gráficos y diversos indicadores. Michael Hypov (2024)

El análisis técnico no considera factores externos como las condiciones macroeconómicas o los cambios en la gestión de una empresa, sino que se centra exclusivamente en los datos de mercado.

Uno de los indicadores más comunes es la *Media Móvil* (MA), que calcula el precio promedio de una acción durante un periodo de tiempo determinado. Las medias móviles ayudan a suavizar las fluctuaciones diarias de los precios, lo que facilita la identificación de tendencias. Existen varios tipos de medias móviles, siendo las más empleadas la media móvil simple (SMA), que calcula el promedio aritmético, y la media móvil exponencial (EMA), que otorga mayor peso a los precios recientes, haciéndola más sensible a los cambios actuales en el mercado.

Otro indicador muy utilizado es el *Índice de Fuerza Relativa* (RSI), un oscilador que mide la velocidad y el cambio de los movimientos de precio. Este indicador es especialmente útil para identificar condiciones de sobrecompra o sobreventa en el mercado. Un valor de RSI superior a 70 puede indicar que una acción está sobrecomprada, mientras que un valor inferior a 30 sugiere que está sobrevendida. Esto puede generar señales de venta o compra, respectivamente.

El *Convergencia/Divergencia de Medias Móviles* (MACD) es otro indicador ampliamente reconocido en el análisis técnico. Este indicador combina dos medias móviles de diferente longitud para identificar posibles cruces que indican el inicio de nuevas tendencias. El MACD es particularmente útil para captar cambios en la fuerza, dirección y duración de las tendencias en el mercado.

Por otro lado, el *Índice de Canal de Materias Primas* (CCI) es un indicador que mide el nivel de los precios actuales en relación con un promedio histórico. Se emplea tanto para detectar tendencias como para identificar condiciones extremas de sobrecompra o sobreventa. Un valor alto del CCI sugiere que los precios están por encima de su valor medio, lo que puede indicar una posible reversión a la baja, mientras que un valor bajo indica lo contrario.

El *Williams %R* es otro oscilador utilizado en el análisis técnico, que compara el precio de cierre más reciente con el rango de precios de un periodo determinado. Este indicador sirve para identificar si una acción se encuentra cerca de su máximo o mínimo reciente, lo que proporciona señales de compra o venta basadas en el comportamiento reciente del mercado.

Estos son solo algunos de los muchos indicadores técnicos disponibles para el análisis de precios. Existen otros como las Bandas de Bollinger, el Estocástico y el SAR Parabólico, cada uno con características particulares que los hacen útiles en diferentes contextos. Los traders suelen combinar varios de estos indicadores para obtener una visión más completa del mercado y mejorar la precisión de sus predicciones.

3.3. Predicción con Machine Learning

En los últimos años, el uso de algoritmos de *machine learning* ha ganado popularidad en la predicción de precios de acciones. Estos métodos aprenden de los datos históricos para identificar patrones complejos y hacer predicciones sobre los futuros movimientos de los precios. Las redes neuronales, los árboles de decisión y los modelos de regresión son algunas de las técnicas más utilizadas en este campo, superando en muchos casos a los métodos tradicionales debido a su capacidad para capturar relaciones no lineales en los datos de series temporales.

3.4. Conclusión

La predicción de precios en la bolsa de valores es una tarea complicada debido a la naturaleza dinámica y volátil de los mercados financieros. Aunque existen enfoques tradicionales como el análisis técnico y fundamental, los avances en *machine learning* han proporcionado nuevas herramientas para mejorar la precisión de las predicciones. Cada método tiene sus ventajas y limitaciones, por lo que la elección de la técnica más adecuada dependerá del tipo de datos y del horizonte temporal de las predicciones.

Capítulo 4

Datos utilizados en los modelos de predicción

En este capítulo se describen los datos que se utilizarán para el desarrollo de los modelos de predicción basados en redes neuronales artificiales. El objetivo es predecir el precio de acciones en el mercado bursátil, utilizando datos históricos y una serie de indicadores técnicos ampliamente reconocidos. Se detallan las fuentes de los datos, las variables utilizadas y la construcción de los distintos conjuntos de datos.

4.1. Acción seleccionada

Para este estudio, se ha elegido una acción perteneciente al índice Ibex35, que agrupa a las principales empresas cotizadas en la Bolsa de Madrid de Inversión (2024), el principal mercado de valores de España. En concreto, se trabajará con la acción de **Inditex**, una de las empresas más relevantes del índice, lo que asegura que los resultados obtenidos tengan relevancia dentro del contexto del mercado español.

4.2. Datos

4.2.1. Datos financieros históricos

Los datos históricos del precio de las acciones se descargarán de la plataforma `yfinance` kcin999 (2023), una herramienta que proporciona información financiera de diversas acciones, incluyendo precios de apertura (`open`), cierre ajustado (`adj close`), máximos (`high`), mínimos (`low`) y volumen de negociación (`volume`).

4.2.2. Indicadores técnicos

Además de los datos históricos de precios, se calcularán varios indicadores técnicos. Estos indicadores se han seleccionado debido a su amplia utilización en el análisis técnico y su capacidad para proporcionar señales sobre la tendencia, momento, volatilidad y condiciones extremas de los precios.

4.3. Variables utilizadas

El modelo de predicción se desarrollará utilizando tanto datos históricos del precio de las acciones como indicadores técnicos calculados a partir de dichos datos. Las variables utilizadas se describen a continuación.

4.3.1. Variable dependiente

La variable dependiente de los modelos será el **precio de cierre ajustado** (`adj close`), ya que refleja de manera más precisa el valor real que recibirá un inversor, eliminando los efectos de ajustes técnicos como dividendos y *splits*. El precio de cierre ajustado es la variable objetivo en los modelos de predicción.

4.3.2. Variables independientes

En cuanto a los indicadores técnicos, se emplearán tres combinaciones diferentes para los modelos:

Tendencia y Momento

- **SMA (Promedio Móvil Simple)**: Se utiliza para suavizar los precios y ayudar a identificar la dirección de la tendencia general. El cruce de una SMA de corto plazo (como SMA50) con una de largo plazo (como SMA200) puede señalar cambios significativos en la tendencia.

- **MACD (Convergencia/Divergencia de Medias Móviles)**: Mide la diferencia entre dos medias móviles exponenciales (EMA) y ayuda a identificar cambios en la fuerza, dirección, momento y duración de una tendencia. Los cruces del MACD con su línea de señal se utilizan para detectar posibles oportunidades de compra o venta.

- **RSI (Índice de Fuerza Relativa)**: Indica condiciones de sobrecompra o sobreventa al medir la velocidad y el cambio de los movimientos de precios. Un valor alto de RSI sugiere que la acción podría estar sobrecomprada, mientras que un valor bajo indica sobreventa.

Esta combinación permite obtener una visión integral de la tendencia del mercado (SMA), el momento actual de la tendencia (MACD) y las condiciones extremas de compra o venta (RSI). Juntos, ayudan a identificar oportunidades de entrada o salida basadas en el estado general de la tendencia y los niveles extremos de precios.

Tendencia y Volatilidad

- **EMA (Media Móvil Exponencial)**: Da más peso a los precios recientes, permitiendo que el indicador reaccione más rápido a los cambios de precio. Es útil para identificar la tendencia a corto plazo y posibles cambios en la misma.
- **MACD Signal (Línea de Señal del MACD)**: Actúa como una media móvil del MACD y genera señales de compra o venta cuando el MACD cruza esta línea.
- **CCI (Índice de Canal de Productos)**: Mide la desviación del precio respecto a una media móvil, ayudando a identificar condiciones de sobrecompra o sobreventa, así como posibles ciclos de tendencia.

Esta combinación ofrece una visión clara de la tendencia a corto plazo (EMA), confirmaciones de señales de compra o venta (MACD Signal) y condiciones extremas de la tendencia (CCI). Es útil para identificar oportunidades de trading basadas en la tendencia y volatilidad del mercado.

Volumen y Tendencia

- **VWAP (Precio Medio Ponderado por Volumen)**: Proporciona una medida del precio promedio ponderado por el volumen a lo largo de un periodo determinado. Es útil para identificar el precio justo y evaluar el valor relativo de la acción en función del volumen negociado.
- **MACD**: Como en el primer conjunto, el MACD se utiliza para identificar cambios en la dirección y fuerza de la tendencia.
- **Williams %R**: Mide el nivel de sobrecompra o sobreventa en relación con el rango de precios reciente, ayudando a detectar posibles puntos de reversión.

Esta combinación permite evaluar si una acción está correctamente valorada en relación con el volumen negociado (VWAP), detectar cambios en la tendencia (MACD) y condiciones extremas de compra o venta (Williams %R).

A partir de los datos históricos y los indicadores técnicos descritos, se han creado varias bases de datos para probar como variables independientes en los modelos de predicción. Cada una de estas bases de datos tiene como objetivo evaluar cómo diferentes combinaciones de variables pueden influir en la precisión de los modelos de predicción del precio de cierre ajustado. Los conjuntos de datos generados son los siguientes:

- **BD1**: Solo incluye la variable `adj close`, que representa el valor ajustado del cierre diario, el cual elimina los efectos de ajustes técnicos en el precio.
- **BD2**: Incluye todas las variables de precios históricos (`open`, `high`, `low`, `volume`, `adj close`).
- **BD3**: Incluye `adj close` más los indicadores técnicos `SMA`, `MACD` y `RSI`.
- **BD4**: Incluye `adj close` más los indicadores `EMA`, `MACD` y `CCI`.
- **BD5**: Incluye `adj close` más los indicadores `VWAP`, `MACD` y `Williams %R`.

Estas bases de datos serán utilizadas como distintos conjuntos de variables independientes en los modelos de predicción. Cada una de ellas representa una combinación diferente de variables y se probarán para determinar cuál ofrece los mejores resultados en la predicción del precio de las acciones. Dependiendo de los resultados obtenidos, se podrá identificar la combinación de variables más adecuada para predecir el precio de las acciones en la Bolsa de Madrid.

Cabe destacar la intención de usar un histórico de noticias financieras sobre la acción a predecir, para así hacer un análsis del sentimiento, en este caso mediante `SentimentIntensityAnalyzer`, el analizador de sentimientos de VADER Hutto and Gilbert (2014), y usar el score de sentimiento como una variable independiente más. No obstante, no se realizó debido a que no encontramos ninguna página web o API gratuita que permitiera descargar noticias de hace más de un año.

Capítulo 5

Arquitecturas de redes neuronales

En este capítulo se detallan las diferentes arquitecturas de redes neuronales que se utilizarán para la predicción de precios de acciones. Cada tipo de red neuronal tiene características específicas que la hacen adecuada para el análisis de series temporales, como es el caso de los precios de las acciones. A continuación, se describen las arquitecturas que se probarán, junto con una explicación de su idoneidad para esta tarea.

5.1. Redes Neuronales Recurrentes (RNN)

Las Redes Neuronales Recurrentes (RNN) son un tipo de red neuronal diseñada para manejar secuencias de datos. A diferencia de las redes neuronales tradicionales, las RNN tienen conexiones cíclicas que les permiten mantener una memoria interna de las secuencias anteriores, lo que es útil para capturar la dependencia temporal en los datos de series temporales Fernando Carazo Melo (2024).

5.1.1. Ventajas de las RNN para la predicción de precios

Las RNN son particularmente adecuadas para la predicción de precios de acciones debido a su capacidad para capturar patrones temporales en los datos históricos. Dado que los precios de las acciones están relacionados con eventos pasados y tendencias, las RNN pueden aprender y modelar estas relaciones temporales de manera efectiva. Sin embargo, las RNN simples pueden enfrentar problemas como el desvanecimiento del gradiente durante el entrenamiento, lo que limita su capacidad para aprender dependencias a largo plazo.

5.1.2. Estructura

Para la arquitectura de RNN simple, se han probado dos estructuras de capas.

- **SimpleRNN 1**: La primera estructura comienza con una capa de RNN con 30 unidades y continúa con capas sucesivas de 40, 50 y 60 unidades, cada una seguida por una

capa de *Dropout* del 10 % para evitar el sobreajuste.

- **SimpleRNN 2**: La segunda estructura utiliza un enfoque más uniforme, con cuatro capas RNN de 50 unidades, todas ellas también acompañadas por capas de *Dropout*, aunque con una tasa de 20 %.

5.2. Long Short-Term Memory (LSTM)

Las redes LSTM son una variante de las RNN diseñadas para superar las limitaciones de las RNN tradicionales, especialmente el problema del desvanecimiento del gradiente. Las LSTM incorporan una estructura de celda que permite a la red mantener información a lo largo de períodos más largos, mediante el uso de puertas que regulan el flujo de información Fernando Carazo Melo (2024).

5.2.1. Ventajas de las LSTM para la predicción de precios

Las LSTM son altamente efectivas para la predicción de precios de acciones porque pueden capturar dependencias a largo plazo en los datos de series temporales. Esto es crucial para el análisis de precios, ya que las tendencias y patrones pueden desarrollarse a lo largo de extensos períodos. Las LSTM pueden retener información relevante y descartar datos irrelevantes, mejorando así la precisión de las predicciones en comparación con las RNN tradicionales.

5.2.2. Estructura

En el caso de las LSTM, se han probado dos configuraciones.

- **LSTM 1**: La primera sigue una estructura incremental, comenzando con una capa LSTM de 30 unidades y avanzando a través de 40, 50 y 60 unidades, con un *Dropout* del 10 % después de cada capa.

- **LSTM 2**: La segunda configuración emplea capas uniformes de 50 unidades y un *Dropout* del 20 %, manteniendo un enfoque más sencillo pero con mayor regularización.

5.3. LSTM con Capa Convolucional 1D

La combinación de LSTM con una capa convolucional 1D introduce una capa convolucional antes de la capa LSTM. La capa convolucional se encarga de extraer características locales de las secuencias de datos, mientras que la capa LSTM modela las dependencias temporales.

5.3.1. Ventajas de las LSTM con Capa Convolucional 1D para la predicción de precios

Integrar una capa convolucional 1D con LSTM puede mejorar la capacidad del modelo para capturar patrones locales en los datos, como las características y estructuras específicas en las series temporales de precios. La capa convolucional puede detectar patrones de corto plazo en los datos de precios, mientras que la LSTM se encarga de aprender las relaciones a largo plazo. Esta combinación puede resultar en una mejora significativa en la precisión de las predicciones, al permitir que el modelo capture tanto las características locales como las dependencias temporales en los datos de precios.

No obstante, una de las desventajas asociadas a la CNN LSTM es el ajuste adecuado de los hiperparámetros y la gestión del equilibrio entre las capas convolucionales y las capas LSTM. Es crucial encontrar el equilibrio adecuado entre las capas convolucionales y las capas LSTM para evitar un sesgo excesivo hacia las características espaciales o las dependencias temporales Varela (2023).

5.3.2. Estructura

Para la combinación de LSTM y una capa convolucional 1D (CNN-LSTM), ambas configuraciones inician con una capa *Conv1D* de 64 filtros y un *MaxPooling*.

- **CNN LSTM 1**: La primera estructura combina esta capa convolucional con tres capas LSTM de 50 unidades, todas con un *Dropout* del 20 %.

- **CNN LSTM 2**: En la segunda estructura, las capas LSTM tienen 30, 40 y 50 unidades respectivamente, con un *Dropout* del 10 %.

5.4. Gated Recurrent Unit (GRU)

GRU se diseñó como una alternativa simplificada a las LSTM (Long Short-Term Memory), manteniendo un rendimiento competitivo en muchas tareas de predicción temporal, pero con menos parámetros y una estructura más sencilla.

La principal diferencia entre GRU y LSTM es la forma en que gestionan el estado de las células de memoria. En la LSTM, el estado de la célula de memoria se mantiene separado del estado oculto y se actualiza mediante tres puertas: la puerta de entrada, la puerta de salida y la puerta del olvido. En GRU, el estado de la célula de memoria se sustituye por un «vector de activación candidato» que se actualiza mediante dos puertas: la puerta de reinicio y la puerta de actualización Anishnama (2023).

5.4.1. Ventajas de las GRU para la predicción de precios

Las GRU presentan varias ventajas para la predicción de precios de acciones en comparación con las redes neuronales recurrentes tradicionales y las LSTM. En primer lugar, son más eficientes desde el punto de vista computacional, ya que tienen una estructura más sencilla y, por lo tanto, requieren menos tiempo de entrenamiento y menos recursos. Esto las convierte en una opción adecuada para aplicaciones en las que la velocidad es importante, como la predicción de precios en tiempo real. Además, al tener menos parámetros que las LSTM, las GRU son más fáciles de entrenar y menos propensas al sobreajuste, lo que es útil cuando se dispone de menos datos. A pesar de su simplicidad, las GRU son capaces de capturar dependencias a largo plazo en los datos, lo que las hace igualmente efectivas para modelar series temporales como los precios de acciones, ofreciendo un rendimiento competitivo con respecto a las LSTM.

5.4.2. Estructura

Las arquitecturas basadas en GRU también siguen dos enfoques.

- **GRU 1**: La primera estructura utiliza capas GRU con 30, 40, 50 y 60 unidades, cada una acompañada de un *Dropout* del 10 %.
- **GRU 2**: La segunda estructura adopta un diseño más simple, con capas GRU uniformes de 50 unidades y un *Dropout* del 20 % después de cada capa para mejorar la generalización del modelo.

Cada uno de estos modelos ha sido entrenado utilizando el optimizador *Adam* y la función de pérdida de error cuadrático medio, con un *callback* de *EarlyStopping* para optimizar el proceso de entrenamiento.

Capítulo 6

Resultados

Hemos creado los diferentes modelos con un conjunto de entrenamiento (80 % de las observaciones) y hemos probado el modelo sobre un conjunto de test (20 % de las observaciones). Para medir cómo de bien actúa cada modelo sobre los datos no vistos durante el entrenamiento, datos de test, hemos usado tres métricas que son las comunes en los métodos de regresión Nicolás Arrioja Landa Cosio (2021):

- **Error absoluto medio, mean absolute error (MAE)**. Esta métrica es una medida de la diferencia entre dos valores, es decir, nos permite saber que tan diferente es el valor predicho y el valor real u observado. Para que un error con valor positivo no cancele a un error con error negativo usamos el valor absoluto de la diferencia.
- **Error medio cuadrado, mean square error (MSE)**. Esta métrica es muy útil para saber que tan cerca es la línea de ajuste de nuestra regresión a las observaciones. Al igual que en caso anterior evitamos que un error con valor positivo anule a uno con valor negativo, pero en lugar de usar el valor absoluto, elevamos al cuadrado la diferencia.
- **Raíz del error medio cuadrado, root mean square error (RMSE)**. Como la métrica anterior nos da el resultado en unidades cuadradas, para poder interpretarlo más fácilmente sacamos la raíz cuadrada y de esta manera tenemos el valor en las unidades originales.

En las siguientes cuatro tablas veremos los resultados obtenidos. Se han dividido de tal forma que cada una de las tablas tienen una de las arquitecturas de red neuronal (recurrente simple, recurrente LSTM, recurrente LSTM con una capa convolucional de una dimensión o GRU) que estamos probando. Dentro cada una de las tablas se ha dividido los dos modelos propuestos. Estas arquitecturas, luego, se han dividido por las variables independientes utilizadas para la predicción.

Model	Variables	MAE	MSE	RMSE
SimpleRNN_1	['Adj Close']	2.2405	13.3717	3.6567
SimpleRNN_2	['Adj Close']	2.7159	21.2486	4.6096
SimpleRNN_1	['Open', 'High', 'Low', 'Volume', 'Adj Close']	1.8007	10.0334	3.1676
SimpleRNN_2	['Open', 'High', 'Low', 'Volume', 'Adj Close']	3.2673	31.8018	5.6393
SimpleRNN_1	['Adj Close', 'SMA_20', 'MACD', 'RSI']	3.0457	32.2575	5.6796
SimpleRNN_2	['Adj Close', 'SMA_20', 'MACD', 'RSI']	4.0462	46.6142	6.8275
SimpleRNN_1	['Adj Close', 'EMA_20', 'MACD', 'CCI']	2.8577	29.5201	5.4332
SimpleRNN_2	['Adj Close', 'EMA_20', 'MACD', 'CCI']	3.8126	44.3379	6.6587
SimpleRNN_1	['Adj Close', 'VWAP', 'MACD', 'Williams_%R']	3.3116	35.5332	5.9610
SimpleRNN_2	['Adj Close', 'VWAP', 'MACD', 'Williams_%R']	3.7135	42.4829	6.5179

Tabla 6.1: RNN simple - Modelos y métricas

Model	Variables	MAE	MSE	RMSE
LSTM_1	['Adj Close']	0.9744	2.1910	1.4802
LSTM_2	['Adj Close']	1.2634	3.5975	1.8967
LSTM_1	['Open', 'High', 'Low', 'Volume', 'Adj Close']	1.4237	6.4396	2.5376
LSTM_2	['Open', 'High', 'Low', 'Volume', 'Adj Close']	2.5430	20.1896	4.4933
LSTM_1	['Adj Close', 'SMA_20', 'MACD', 'RSI']	2.6913	18.6312	4.3164
LSTM_2	['Adj Close', 'SMA_20', 'MACD', 'RSI']	2.1582	12.7323	3.5682
LSTM_1	['Adj Close', 'EMA_20', 'MACD', 'CCI']	1.3343	4.0453	2.0113
LSTM_2	['Adj Close', 'EMA_20', 'MACD', 'CCI']	1.5215	5.0481	2.2468
LSTM_1	['Adj Close', 'VWAP', 'MACD', 'Williams_%R']	2.4857	21.1073	4.5943
LSTM_2	['Adj Close', 'VWAP', 'MACD', 'Williams_%R']	2.4516	19.9864	4.4706

Tabla 6.2: LSTM - Modelos y métricas

Model	Variables	MAE	MSE	RMSE
CNN_LSTM_1	['Adj Close']	1.9267	12.1606	3.4872
CNN_LSTM_2	['Adj Close']	1.8217	11.6589	3.4145
CNN_LSTM_1	['Open', 'High', 'Low', 'Volume', 'Adj Close']	2.0997	10.9661	3.3115
CNN_LSTM_2	['Open', 'High', 'Low', 'Volume', 'Adj Close']	1.1948	3.9503	1.9875
CNN_LSTM_1	['Adj Close', 'SMA_20', 'MACD', 'RSI']	1.5619	5.5374	2.3532
CNN_LSTM_2	['Adj Close', 'SMA_20', 'MACD', 'RSI']	1.8060	8.5560	2.9251
CNN_LSTM_1	['Adj Close', 'EMA_20', 'MACD', 'CCI']	1.7834	9.8023	3.1309
CNN_LSTM_2	['Adj Close', 'EMA_20', 'MACD', 'CCI']	1.3020	4.8787	2.2088
CNN_LSTM_1	['Adj Close', 'VWAP', 'MACD', 'Williams_%R']	1.2879	3.9872	1.9968
CNN_LSTM_2	['Adj Close', 'VWAP', 'MACD', 'Williams_%R']	1.4372	6.1628	2.4825

Tabla 6.3: CNN LSTM - Modelos y métricas

Model	Variables	MAE	MSE	RMSE
GRU_1	['Adj Close']	0.9297	1.3782	1.1740
GRU_2	['Adj Close']	1.0603	1.9909	1.4110
GRU_1	['Open', 'High', 'Low', 'Volume', 'Adj Close']	0.7800	0.9646	0.9822
GRU_2	['Open', 'High', 'Low', 'Volume', 'Adj Close']	1.4675	4.0235	2.0059
GRU_1	['Adj Close', 'SMA_20', 'MACD', 'RSI']	0.9756	2.0614	1.4358
GRU_2	['Adj Close', 'SMA_20', 'MACD', 'RSI']	2.1288	7.7006	2.7750
GRU_1	['Adj Close', 'EMA_20', 'MACD', 'CCI']	1.2229	3.0565	1.7483
GRU_2	['Adj Close', 'EMA_20', 'MACD', 'CCI']	1.0660	2.6957	1.6419
GRU_1	['Adj Close', 'VWAP', 'MACD', 'Williams_%R']	0.7913	1.4192	1.1913
GRU_2	['Adj Close', 'VWAP', 'MACD', 'Williams_%R']	1.6852	5.0267	2.2420

Tabla 6.4: GRU - Modelos y métricas

Capítulo 7

Conclusiones y trabajos futuros

Para seleccionar el mejor modelo para predecir el 'Adj Close' de una acción en bolsa, deberíamos considerar principalmente el error de predicción medido por el RMSE (Root Mean Squared Error), ya que el RMSE da una idea clara de cuánto se desvía la predicción del valor real en promedio. Un menor RMSE indica una mejor precisión del modelo. En la siguiente tabla se han recogido los mejores modelos que tienen valor RMSE más bajo:

Model	**Variables**	**MAE**	**MSE**	**RMSE**
GRU_1	['Open', 'High', 'Low', 'Volume', 'Adj Close']	0.7800	0.9646	0.9822
GRU_1	['Adj Close']	0.9297	1.3782	1.1740
GRU_1	['Adj Close', 'SMA_20', 'MACD', 'RSI']	0.9756	2.0614	1.4358
CNN_LSTM_1	['Adj Close', 'VWAP', 'MACD', 'Williams_%R']	1.2879	3.9872	1.9968
GRU_2	['Adj Close']	1.0603	1.9909	1.4110
CNN_LSTM_2	['Adj Close', 'VWAP', 'MACD', 'Williams_%R']	1.4372	6.1628	2.4825
LSTM_1	['Adj Close', 'EMA_20', 'MACD', 'CCI']	1.3343	4.0453	2.0113

Tabla 7.1: Modelos con los 7 valores más bajos de RMSE

De acuerdo con el RMSE, el mejor modelo es el **GRU_1** con las variables **['Open', 'High', 'Low', 'Volume', 'Adj Close']**, que tiene el RMSE más bajo de 0.9822. Este modelo parece ser el más preciso para predecir el 'Adj Close' entre los modelos evaluados.

A continuación, para ver visualmente la gran capacidad de este modelo sobre los datos del conjunto de test, se muestra un gráfico que compara los valores reales y los predichos.

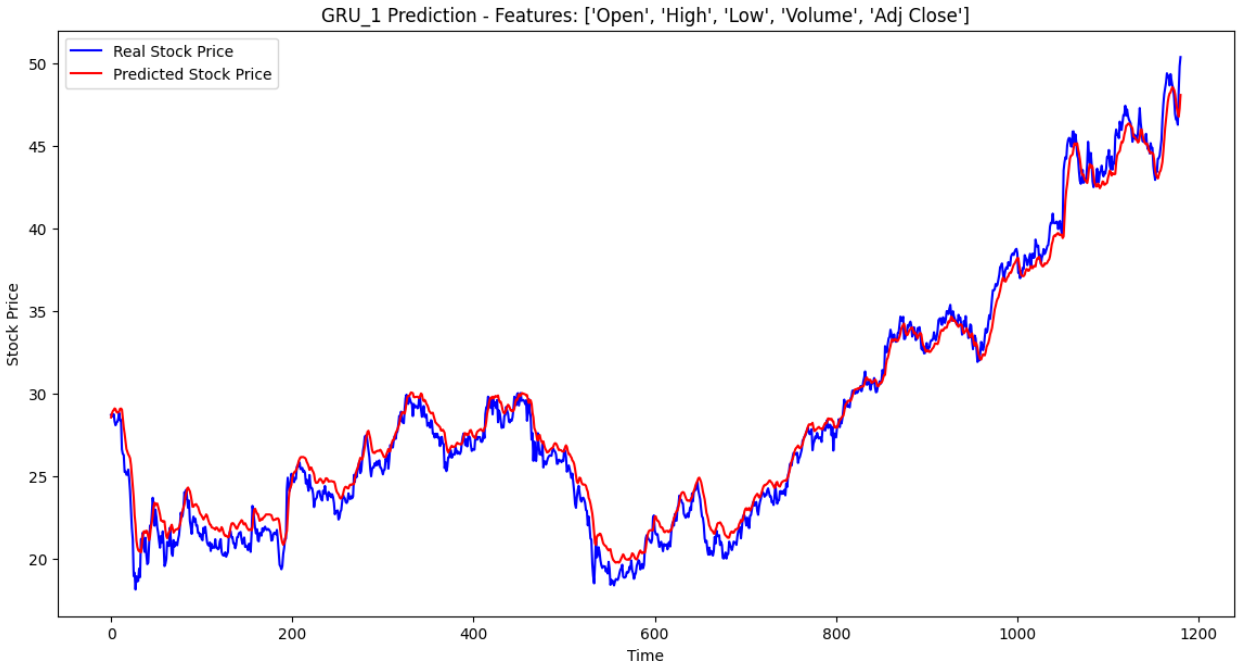


Figura 7.1: Valores reales vs. predichos para el modelo GRU1 con variables independientes 'Open', 'High', 'Low', 'Volume', 'Adj Close'.

7.1. Trabajos futuros

Para mejorar y extender el análisis presentado en este trabajo, se proponen las siguientes líneas de investigación:

1. **Optimización de hiperparámetros:** Actualmente, los modelos se han evaluado con una configuración fija de hiperparámetros. En futuros trabajos, se llevará a cabo una búsqueda de parámetros exhaustiva para identificar las combinaciones óptimas de hiperparámetros. Este proceso, conocido como optimización de hiperparámetros, podría mejorar significativamente el rendimiento de los modelos. Sin embargo, debido a la carga computacional que implica probar múltiples combinaciones, este análisis requerirá un ordenador con mayor capacidad de procesamiento.

2. **Incorporación de análisis de sentimiento:** Se explorará la integración de variables basadas en el análisis de sentimiento a partir de noticias financieras. Para ello, es necesario acceder a bases de datos extensas de noticias financieras pasadas. La incorporación de estas variables podría proporcionar una dimensión adicional al modelo, potencialmente mejorando la capacidad predictiva al captar el impacto de la percepción del mercado sobre los precios de las acciones.

Estas mejoras podrían ofrecer una comprensión más profunda y precisa de las dinámicas del mercado y, en consecuencia, optimizar las predicciones del 'Adj Close'.

Bibliografía

Rankia. Teoría del paseo aleatorio, 2023. URL https://www.rankia.com/diccionario/bolsa/teoria-paseo-aleatorio.

Amazon Web Services. ¿qué es una red neuronal?, 2024. URL https://aws.amazon.com/es/what-is/neural-network/.

Anishnama. Understanding gated recurrent unit (gru) in deep learning. *Medium*, 2023. URL https://medium.com/@anishnama20/understanding-gated-recurrent-unit-gru-in-deep-learning-2e54923f3e2.

Central Charts. Indicador técnico. *Central Charts*, 2024. URL https://www.centralcharts.com/es/gm/1-aprender/7-analisis-tecnico/26-indicador-tecnico.

Sitio Big Data. Machine learning: Métricas de regresión (mse). *Sitio Big Data*, 2018. URL https://sitiobigdata.com/2018/08/27/machine-learning-metricas-regresion-mse/.

Python Software Foundation. Python documentation, 2024. URL https://www.python.org/doc/.

Bolsas y Mercados. ¿qué es la bolsa?, 2024. URL https://bolsasymercados.es/bme-exchange/es/Para-Inversores/Que-es-la-Bolsa. Accedido: 7-sept-2024.

CNMV. *El mercado de valores y los productos de inversión Manual para universitarios*. CNMV, España, 2024. URL https://www.cnmv.es/DocPortal/Publicaciones/Guias/ManualUniversitarios.pdf.

XTB. Acciones, 2024. URL https://www.xtb.com/es/educacion/acciones. Accedido: 02-sept-2024.

Martín Guimerà Castell. Predicción de índices bursátiles por medio de redes neuronales artificiales. aplicación al caso del ibex-35, 2020. URL https://riunet.upv.es/bitstream/handle/10251/152246/Guimer%C3%A1%20-%20Predicci%C3%B3n%20de%20%C3%ADndices%20burs%C3%A1tiles%20por%20medio%20de%20redes%20neuronales%20artificiales.%20Aplicaci%C3%B3n....pdf.

Degiro. ¿qué es el análisis fundamental y cómo funciona?, 2024. URL https://www.degiro.es/estrategias/analisis-fundamental.

Michael Hypov. Indicador técnico. *Lite Finance*, 2024. URL https://www.litefinance.org/es/blog/for-beginners/que-es-analisis-tecnico/.

Estrategias de Inversión. Bolsa de madrid: Definición y características, 2024. URL https://www.estrategiasdeinversion.com/herramientas/diccionario/mercados/bolsa-de-madrid-t-1414. Accedido: 15-sept-2024.

kcin999. Introduction to yahoo finance in r, 2023. URL https://rpubs.com/kcin999/yahoo-finance. Accedido: 7-sept-2024.

C.J. Hutto and E.E. Gilbert. Vader: A parsimonious rule-based model for sentiment analysis of social media text. In *Eighth International Conference on Weblogs and Social Media (ICWSM-14)*, Ann Arbor, MI, June 2014.

Fernando Carazo Melo. Deep learning para la predicción de series temporales: Redes neuronales recurrentes (rnn) y long short-term memory (lstm). *Skforecast*, 2024. URL https://cienciadedatos.net/documentos/py54-forecasting-con-deep-learning.

Ainhoa Gallego Varela. Predicción de la cotización de acciones en bolsa mediante deep learning, 2023. URL https://repositorio.comillas.edu/jspui/bitstream/11531/69007/2/TFG-%20Gallego%20Varela%2C%20Ainhoa.pdf.

Nicolás Arrioja Landa Cosio. Métricas en regresión. *Medium*, 2021. URL https://medium.com/@nicolasarrioja/m%C3%A9tricas-en-regresi%C3%B3n-5e5d4259430b.